Innovación en Formación Profesional

Planeta Formación y Universidades

Proyecto de big data e inteligencia artificial

Fase 1

CURSO DE ESPECIALIZACIÓN EN

INTELIGENCIA ARTIFICIAL Y BIG DATA

MODALIDAD ONLINE

Innovación en Formación Profesional

Planeta Formación y Universidades

1. Título del proyecto + integrantes del equipo **3**
2.Resumen ejecutivo **3**
3. Descripción funcional del sistema 4
3.1 Qué hace exactamente la aplicación 4
3.2 Flujo general de uso 4
3.3 Casos principales de usuario 5
Caso 1: Clasificación individual de texto 5
Caso 2: Consulta de métricas agregadas (si se implementa dashboard) 5
Caso 3: Uso vía API (perfil técnico) 5
3.4 Qué puede y qué no puede hacer el sistema 6
El sistema puede: 6
El sistema no puede: 6
Funcionalidades minimas 6
Funcionalidades opcionales (si hay tiempo) 7
No incluye (elementos descartados explícitamente) 7
5. Arquitectura del sistema (alto nivel) **7**
Diagrama de arquitectura 7
Descripción de componentes 8
Frontend 8
Backend 8
Base de datos 8
Servicio ML 8
Pipeline de datos 8
Dashboard 9
6. Tecnologías seleccionadas **9**
Lenguajes 9
Framework Backend 9
Librerías principales 10
Base de datos 10
Herramientas auxiliares 10
7. Modelo de datos **11**
8. Datos 12
Análisis Exploratorio de Datos (EDA) 12
Preprocesamiento de datos 13
Observaciones relevantes 13
9. Ética, legalidad y accesibilidad **14**
PII 14
GDPR 14
Riesgos de sesgo 14
Mitigación 14
Accesibilidad 14
10. Backlog inicial (10 historias) **15**
11. Plan de trabajo (ejemplo 6 semanas) **16**
12. Estrategia de desarrollo **17**
Flujo Git 17
Integración 17
Validación 17
Testing 17

1. Título del proyecto + integrantes del equipo

Sistema de análisis de sentimiento en reseñas de productos en español mediante modelos NLP y pipeline Big Data

Hacemos todo entre todos pero para tener una estructura de tareas lo hemos definido asi:

- **Edgar 1 – Data Engineer / Data Analyst**
  - Búsqueda y selección de datasets.
  - Ingesta de datos.
  - Limpieza y preprocesamiento de texto.
  - Análisis exploratorio de datos (EDA).
- **Persona 2 – Machine Learning Engineer**
  Selección del enfoque de modelado.
  - Entrenamiento de modelos de análisis de sentimiento.
  - Ajuste de hiperparámetros.
  - Evaluación del rendimiento del modelo.
- **Persona 3 – NLP / Research**
  - Investigación de técnicas NLP adecuadas.
  - Pruebas con modelos preentrenados.
  - Comparación de enfoques clásicos vs deep learning.
  - Apoyo en interpretación de resultados.
- **Andrés – Platform / MLOps / Documentación**
  - Estructura del repositorio.
  - Scripts de ejecución o API básica.
  - Preparación del entorno de desarrollo.
  - Documentación técnica y coordinación de entregables.

2.Resumen ejecutivo

Actualmente, muchas organizaciones reciben grandes cantidades de texto en forma de reseñas, comentarios, encuestas o mensajes en redes sociales. Este contenido suele analizarse de forma manual o superficial.

El análisis manual es lento, costoso, subjetivo y poco escalable. Como consecuencia, se pierde información

valiosa sobre la opinión real de los usuarios.
Detectar el sentimiento de forma automática permite comprender tendencias, anticipar problemas, mejorar productos o servicios y tomar decisiones basadas en datos reales.

Además, el crecimiento exponencial de datos textuales en plataformas digitales hace necesario el uso de técnicas de Big Data y procesamiento automático para su análisis eficiente.

3. Descripción funcional del sistema

3.1 Qué hace exactamente la aplicación

La aplicación es un sistema de análisis automático de sentimiento que procesa textos en español y los clasifica según su polaridad emocional.

El sistema:

- Recibe un texto introducido por el usuario.
- Aplica un proceso de preprocesamiento lingüístico (limpieza, normalización y tokenización).
- Transforma el texto en una representación numérica adecuada para el modelo.
- Ejecuta un modelo de Machine Learning previamente entrenado.
- Devuelve:
    - La categoría de sentimiento (positivo, negativo o neutro).
    - Una probabilidad o nivel de confianza asociado.
- (Opcionalmente) almacena el texto y su predicción en una base de datos para análisis posterior.

El sistema no genera texto nuevo ni modifica el contenido original; únicamente realiza clasificación.

3.2 Flujo general de uso

El flujo funcional del sistema es el siguiente:

1. El usuario accede a la aplicación (interfaz o endpoint API).
2. Introduce un texto en un campo de entrada.
3. El backend recibe la solicitud.
4. El módulo NLP preprocesa el texto:
    - Eliminación de caracteres irrelevantes.
    - Normalización.
    - Tokenización.

5. El texto procesado se transforma en vectores (TF-IDF o embeddings).
6. El modelo entrenado realiza la predicción.
7. El sistema devuelve el resultado al usuario.

8. (Opcional) Se guarda la predicción en la base de datos.

Flujo simplificado:

Usuario → API → Preprocesamiento → Modelo ML → Resultado → Usuario

3.3 Casos principales de usuario

Caso 1: Clasificación individual de texto

Como usuario, quiero introducir un texto para obtener automáticamente su sentimiento.

Resultado esperado:

- El sistema devuelve la categoría de sentimiento.
- Se muestra el nivel de confianza.

Caso 2: Consulta de métricas agregadas (si se implementa dashboard)

Como usuario, quiero visualizar estadísticas generales sobre los textos analizados.

Resultado esperado:

- Distribución porcentual de sentimientos.
- Métricas del modelo (accuracy, precision, recall).
- Visualización gráfica básica.

Caso 3: Uso vía API (perfil técnico)

Como desarrollador, quiero enviar texto mediante una petición HTTP para integrar el sistema en otra aplicación.

Resultado esperado:

- Endpoint REST funcional.
- Respuesta en formato JSON.
- Código de estado adecuado.

3.4 Qué puede y qué no puede hacer el sistema

El sistema puede:

- Clasificar textos en positivo, negativo o neutro.
- Procesar textos en español.
- Trabajar con datasets públicos.
- Devolver probabilidades asociadas a la predicción.
- Integrarse mediante API REST.
- Almacenar resultados para análisis posterior.

El sistema no puede:

- Detectar sarcasmo o ironía compleja.
- Interpretar contexto externo al texto proporcionado.
- Analizar emociones específicas (alegría, tristeza, ira, etc.).
- Garantizar precisión del 100%.
- Procesar múltiples idiomas (en la versión inicial).
- Operar en tiempo real con alto volumen concurrente.
- Sustituir análisis humano en casos críticos.

4. Alcance definitivo (IN / OUT)

Funcionalidades minimas

- Análisis de sentimiento en textos en español.
- Clasificación básica: positivo, negativo y neutro.
- Uso de datasets públicos.
- Entrenamiento y evaluación de al menos un modelo de Machine Learning / Deep Learning.
- Exposición de resultados mediante script o API sencilla.

- Pipeline de procesamiento de datos
- Evaluación con métricas de ML (Accuracy, F1-score)

Funcionalidades opcionales (si hay tiempo)

- Análisis multiclase (muy positivo / positivo / neutro / negativo / muy negativo).
- Soporte multilingüe (español + inglés).
- Visualización interactiva de resultados.
- Comparación entre modelo clásico (Logistic Regression) y modelo basado en transformers.
- API REST desplegable en entorno cloud.
- Exportación de resultados en CSV.
- Dashboard con métricas en tiempo real.

No incluye (elementos descartados explícitamente)

- Análisis de sarcasmo o ironía avanzada.
- Procesamiento en tiempo real con streaming.
- Entrenamiento continuo automático (MLOps avanzado).
- Uso de datos privados o datos con PII real.
- Infraestructura de producción escalable.

5. Arquitectura del sistema (alto nivel)

Diagrama de arquitectura

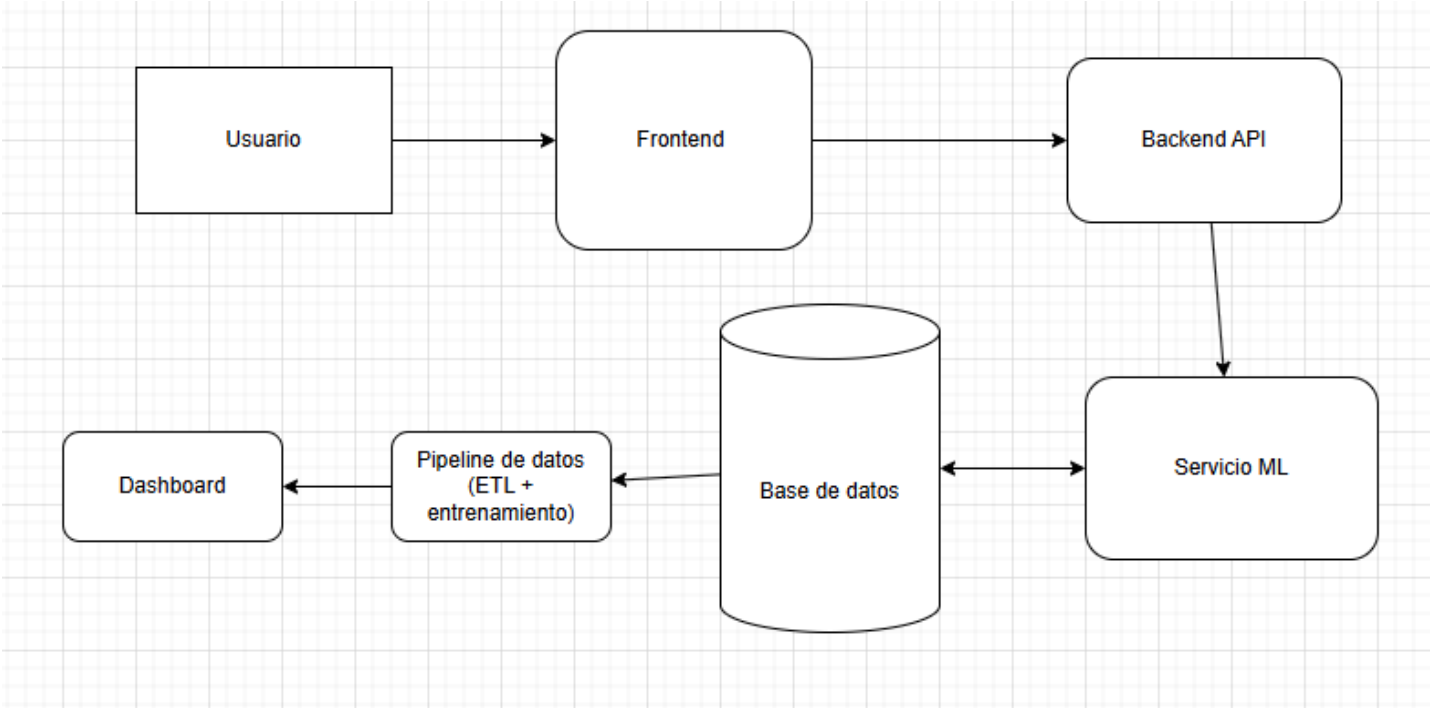

Descripción de componentes

Frontend

- Interfaz sencilla para introducir texto.
- Visualiza resultado del sentimiento.
- Puede ser Streamlit o una interfaz mínima.

Backend

- API REST desarrollada con FastAPI.
- Recibe texto y devuelve clasificación.
- Conecta con modelo entrenado.

Base de datos

- Almacena:
    - Textos analizados.
    - Predicciones.
    - Métricas.
- Puede ser PostgreSQL o SQLite (según complejidad).

Servicio ML

- Modelo entrenado de análisis de sentimiento.
- Puede ser:
    - Logistic Regression + TF-IDF.
    - Modelo basado en BERT preentrenado.
- Se expone como servicio interno.

Pipeline de datos

Incluye:

- Ingesta de dataset.
- Limpieza.
- Tokenización.
- Vectorización.
- División train/test.

- Entrenamiento.
- Evaluación.

Dashboard

- Visualización de:
    - Distribución de sentimientos.
    - Accuracy.
      Matriz de confusión.
- Puede implementarse con Streamlit o simple notebook exportado.

6. Tecnologías seleccionadas

Lenguajes

Python

- Estándar en NLP y ML.
- Amplio ecosistema.
- Fácil integración con APIs.

Alternativa descartada: R (menor integración con APIs web modernas).

Framework Backend

FastAPI

- Ligero.
- Alto rendimiento.
- Documentación automática.
- Fácil integración con modelos ML.

Alternativa descartada: Flask (menos tipado y menos automático).

Librerías principales

- scikit-learn → Modelos clásicos.
- spaCy → Preprocesamiento NLP.
- transformers → Modelos preentrenados.
- pandas → Manipulación de datos.
- matplotlib / seaborn → Visualización.

Base de datos

SQLite (fase académica)

- Ligera.
- Fácil despliegue.
- No requiere servidor externo.

Alternativa futura: PostgreSQL.

Herramientas auxiliares

- Git + GitHub → Control de versiones.
- Jupyter Notebook → Experimentación.

- Docker (opcional) → Contenerización.

7. Modelo de datos

Diccionario de variables (dataset)

Variable		Descripción
review_body		Texto de la reseña
stars		Valoración de 1 a 5 estrellas
language		Idioma de la reseña
sentiment		Etiqueta generada (positivo, neutro, negativo)

8. Datos

Fuente
Se ha utilizado el dataset *Amazon Reviews Multi*, obtenido desde Kaggle. Este dataset contiene reseñas de productos en múltiples idiomas.

Licencia
Licencia abierta para uso académico.

Tipo de datos
Texto no estructurado correspondiente a opiniones de usuarios.

Volumen estimado
Se trabajará con un subconjunto de entre 20.000 y 50.000 registros para facilitar el procesamiento.

Frecuencia
Dataset estático.

Calidad esperada

- Texto informal.
- Presencia de ruido (símbolos, errores ortográficos, etc.).
- Posible desbalanceo de clases.

Riesgos

- Datos faltantes.
- Sesgo cultural.
- Ambigüedad en el lenguaje.

Ingesta de datos
Los datos se descargan desde Kaggle y se cargan en el sistema mediante la librería pandas, utilizando archivos en formato CSV.

Análisis Exploratorio de Datos (EDA)

Se ha realizado un análisis exploratorio de los datos con el objetivo de comprender su estructura y detectar posibles problemas antes de su uso en modelos de Machine Learning.

En primer lugar, se ha analizado la distribución de las valoraciones (campo *stars*), observándose una mayor presencia de reseñas positivas frente a negativas, lo que indica un posible desbalanceo de clases.

Posteriormente, se ha filtrado el dataset para trabajar únicamente con reseñas en español, ya que el objetivo

del proyecto es el análisis de sentimiento en este idioma.

Además, se ha analizado la longitud de los textos, observando una alta variabilidad en el tamaño de las reseñas, lo que puede influir en el rendimiento de los modelos de procesamiento de lenguaje natural.

Finalmente, se han revisado ejemplos reales de las reseñas, identificando el uso de lenguaje informal, errores ortográficos y la presencia de caracteres innecesarios.

Preprocesamiento de datos

Como parte del pipeline de datos, se han aplicado transformaciones básicas para preparar la información:

- Conversión de texto a minúsculas.
- Eliminación de enlaces y caracteres especiales.
- Filtrado de reseñas en español.
- Creación de una nueva variable de sentimiento a partir de la valoración:
    - 1–2 → negativo
    - 3 → neutro
    - 4–5 → positivo

Estas transformaciones permiten adaptar el dataset para su uso en modelos de análisis de sentimiento.

Observaciones relevantes

- Se detecta un posible desbalanceo de clases que podría afectar al rendimiento del modelo.
- El dataset contiene ruido que requiere limpieza previa.
- El uso de datos reales aporta mayor valor al proyecto, aunque introduce complejidad en el procesamiento.

9. Ética, legalidad y accesibilidad

PII

No se utilizarán datos personales identificables.

GDPR

- Uso exclusivo de datos públicos.
- Anonimización si fuera necesario.

Riesgos de sesgo

- Sesgo cultural.
- Sesgo de lenguaje informal.
- Posible polarización.

Mitigación

- Análisis exploratorio.
- Balanceo de clases.
- Evaluación por métricas desagregadas.

Accesibilidad

Si hay frontend:

- Diseño simple.
- Alto contraste.
- Uso sin registro obligatorio.

10. Backlog inicial (10 historias)

Ejemplo formato resumido:

1. Como usuario quiero introducir un texto para obtener su sentimiento.
    - Criterios:
        - Recibe texto.
        - Devuelve categoría.
        - Devuelve probabilidad.
2. Como desarrollador quiero limpiar el dataset.
3. Como ML engineer quiero entrenar un modelo base.
4. Como equipo quiero evaluar métricas.
5. Como sistema quiero almacenar predicciones.
6. Como usuario quiero ver estadísticas agregadas.
7. Como desarrollador quiero versionar modelos.
8. Como equipo quiero documentar decisiones.
9. Como sistema quiero dividir train/test correctamente.
10. Como usuario quiero exportar resultados.

11. Plan de trabajo (ejemplo 6 semanas)

Semana 1:

- Selección dataset
- EDA

Semana 2:

- Preprocesamiento
- Modelo base

Semana 3:

- Optimización modelo
- Métricas

Semana 4:

- Desarrollo API
- Integración modelo

Semana 5:

- Dashboard
- Testing

Semana 6:

- Documentación final
- Presentación

12. Estrategia de desarrollo

Flujo Git

- main → estable
- develop → integración
- feature/* → nuevas funcionalidades

Integración

- Pull Request obligatorio.
- Revisión mínima por otro miembro.

Validación

- Pruebas manuales.
- Evaluación métricas ML.

Testing

- Test básico de API.
- Validación predicciones coherentes.

13. Riesgos técnicos actualizados

Riesgo	Impacto	Probabilidad	Mitigación
Modelo baja accuracy	Alto	Medio	Cambiar modelo
Dataset desbalanceado	Medio	Alto	Rebalanceo
API no integra modelo	Alto	Bajo	Simplificar arquitectura
Tiempo insuficiente	Alto	Medio	Reducir alcance